

스트레스 지수 예측 예측 AI 해커톤

8조 달린다꽂잡아


AH_02_곽호준

AH_02_한지수

AH_02_탁진선



데이터 탐색 (EDA)



데이터셋 구조 및 변수 확인

타깃 분포 확인

ID: 3000 categories

gender: 2 categories

activity: 3 categories

smoke_status: 3 categories

medical_history: 3 categories

family_medical_history: 3 categories

sleep_pattern: 3 categories

edu_level: 3 categories

주요 변수 분포 분석

결측치: 4414

수치형 데이터 (Numerical)

연속형 (float64): 신장(height), 체중(weight), 콜레스테롤(cholesterol),
혈당(glucose), 골밀도(bone_density), 평균 근무 시간(mean_working), 스트레스
지수(stress_score)


이산형 (int64): 나이(age), 수축기 혈압(systolic_blood_pressure), 이완기
혈압(diastolic_blood_pressure)

범주형 데이터 (Categorical)

명목형 (object): ID(식별자), 성별(gender), 활동량(activity), 흡연
여부(smoke_status), 과거 병력(medical_history), 가족력(family_medical_history),
수면 패턴(sleep_pattern)

순서형 (object): 교육 수준(edu_level)

변수 간 상관관계 파악



문제 유형 정의

결측치 처리

문자형 데이터를 숫자형 데이터로 변환(Ordinal encoding)

원 핫 인코딩 (One-hot encoding)

피쳐 엔지니어링(Feature Engineering)

신체 지표 최적화: BMI (체질량지수)

혈압 관련 상세 지표: 맥압(Pulse Pressure) & 평균 동맥압(MAP)

연령과 활동량(age_activity)

연령과 비만도(age_bmi)




데이터 전처리

Feature Encoding 및 표현 방식

결측치 처리 전략

데이터 전처리 전략



결측치 처리

mean_working 컬럼은 0으로 대체, 나머지는 'Unknown'으로 채움

인코딩

- **Ordinal:** gender, activity, smoke_status, edu_level, sleep_pattern
- **One-Hot:** medical_history, family_medical_history, smoke_status

피처 엔지니어링

- BMI, 맥압(pulse_pressure), 평균동맥압(MAP)
- age × activity, age × BMI 교호작용 변수

학습 데이터 구성

결측치 처리: mean_working은 0으로,
기타 범주형 데이터는 'Unknown'으로 채움

파생 변수

생성: bmi(체질량지수), pulse_pressure(맥압), map_bp(평균
동맥압)와 같이 신체 지표를 활용한
변수와 age_activity, age_bmi 등 상호작용 변수를 생성하여
학습에 활용

입력 데이터 정규화 & 스케일링

RobustScaler: 이상치(Outlier)의 영향을 최소화하면서 피처를 스케일링하는 데 사용

QuantileTransformer: 타겟 변수인 stress_score에 적용되어 데이터를 정규분포 형태로 변환함으로써 회귀 모델(SVR)의 성능을 최적화

One-Hot Encoding: medical_history, smoke_status 등의 범주형 데이터를 수치형 데이터로 변환

데이터 분리

K-Fold 교차 검증: 전체 데이터를 5개의 폴드(Fold)로 나누어 학습과 검증을 반복함으로써 특정 데이터셋에 과적합되는 것을 방지



모델링

모델 아키텍처 설계

Scikit-learn의 Pipeline 기능 파이프라인 기반 아키텍처

전처리 레이어 (Preprocessing Layer) : RobustScaler

대상 변수 변환 레이어 (Target Transformation Layer)
TransformedTargetRegressor
QuantileTransformer

핵심 예측 엔진 (Core Regressor)

SVR (Support Vector Regressor)

스트레스 점수 예측 파이프라인

SVR 기반 머신러닝 파이프라인 — 하이퍼파라미터 최적화, 앙상블 전략, 학습 곡선 분석

파이프라인 전체 구조



Google Drive에서 데이터를 로드하고, 전처리-피처 엔지니어링 후 Hyperopt로 최적 파라미터를 탐색, 최종 앙상블 예측을 수행합니다.

모델 파이프라인 구성

1

RobustScaler

이상치에 강건한 피쳐 스케일링

2

QuantileTransformer

타깃 변수를 정규분포로 변환 (최대 1,000
분위)

3

SVR (RBF 커널)

C, gamma, epsilon 파라미터 최적화 대상



하이퍼파라미터 튜닝

Hyperopt 하이퍼파라미터 최적화

탐색 알고리즘

TPE (Tree-structured Parzen Estimator)

평가 횟수

100회 시도, 5-Fold CV 기반 MAE 최소화

탐색 공간

C: $\log[0.5, 30]$, gamma: $\log[0.05, 5]$, epsilon: $\log[1e-5, 0.1]$





손실 함수 및 최적화 기법

최적화 결과

0.13...

**Best MAE
(CV)**

100회 탐색 후 달성한 최적 교차검
증 MAE

21.25

최적 C

정규화 강도 파라미터

0.9...

최적 γ

RBF 커널 폭 파라미터

$1e-5$

최적 ϵ

손실 함수 민감도 파라미터

학습 전략 설정

Hyperparameter Optimization: Hyperopt 라이브러리를 사용하여 SVR 모델의 핵심 파라미터인 C, gamma, epsilon의 최적 조합 탐색

K-Fold Averaging: 각 폴드에서 학습된 모델들의 예측치를 평균 내어 안정성을 높임

Multi-Seed Averaging: 10개의 서로 다른 시드(Seed)를 사용하여 데이터 셔플링에 따른 변동성을 줄임

모델 비교 및 성능 개선

다양한 예측 전략별 성능(OOF MAE)을 비교

Full (Single) / K-Fold: 0.138090

Multi-Seed: 0.139143

Blend (최종 전략): 0.138483


최종적으로 단일 모델, K-Fold 평균, Multi-Seed 평균
값을 **0.2 : 0.3 : 0.5 비율로 블렌딩(Blending)** 하여 최종
예측 성능을 개선

평가지표 계산

MAE (Mean Absolute Error): 실제값과 예측값의 절대적인 차이의 평균을 측정

Learning Curve 시각화: 학습 데이터 크기에 따른 Training Score와 Cross-validation Score의 변화를 그래프로 그려 모델이 과적합(Overfitting)되지 않고 잘 학습되고 있는지 시각적으로 확인

전략별 OOF MAE 비교



결과 해석

Full 및 K-Fold 전략이 **MAE 0.138090**으로 공동 최우수 성능을 기록했습니다.

Multi-Seed 전략은 0.139143으로 소폭 높았으며, Blend는 중간값인 0.138483을 달성했습니다.

모든 전략에 0.1 클리핑 및 소수점 2자리 반올림 후처리가 적용되었습니다.

앙상블 예측 전략



블렌딩 공식

$$0.2 \times \text{Full} + 0.3 \times \text{K-Fold} + 0.5 \times \text{Multi-Seed}$$

최종 예측값은 0.1 클리핑 및 소수점 2자리 반올림 후처리 적용


Multi-Seed 설정

10개 시드 사용: 42, 123, 456, 789, 2024, 2025, 2026, 777, 1234, 5678



평가

학습 곡선 분석 (SVR)



주요 관찰

- 훈련 MAE ≈ 0.00 : 모델이 훈련 데이터에 완벽히 적합
- CV MAE ≈ 0.25 : 교차검증 점수는 전 구간에서 일정하게 유지
- 훈련 크기 증가에도 CV 점수 개선 없음 → **과적합(Overfitting)** 징후

시사점

하이퍼파라미터 재조정 또는 정규화 강화가 필요할 수 있습니다. 데이터 3,000건, 피쳐 29개 기준.

핵심 요약 및 결론



최적 파라미터

C=21.25, gamma=0.977, epsilon=1e-5



최고 성능

OOF MAE **0.1381** (Full / K-Fold 전략)



앙상블 효과

블렌딩으로 분산 감소 및 안정적 예측 확보



개선 과제

학습 곡선상 과적합 → 정규화 강화 검토 필요

